


# FEDERATED LEARNING IN DER ENERGIEVERSORGUNG




Die moderne Energieversorgung generiert immense Datenmengen – essenziell für Optimierung und Steuerung. **PROBLEM:** Diese Daten sind jedoch sensibel (Betriebsgeheimnisse, Verbrauchsprofile) und liegen dezentral vor. Eine zentrale Sammlung ist durch Datenschutz- und Wettbewerbsbedenken blockiert.

**Recherchefrage:** Wie ermöglicht Federated Learning (FL) die Nutzung dieser Daten, ohne die Privatsphäre zu verletzen, und welche Potenziale birgt es für Smart Grids?

## Was ist Federated Learning (FL)?

FL-Prinzip: KI-Modelle lernen kooperativ auf dezentralen Daten. Rohdaten bleiben lokal, nur Modell-Updates werden ausgetauscht.



## AUTOREN

Maximilian Hanauer  
m.hanauer@oth-aw.de

Paul Breu  
p.breu@oth-aw.de



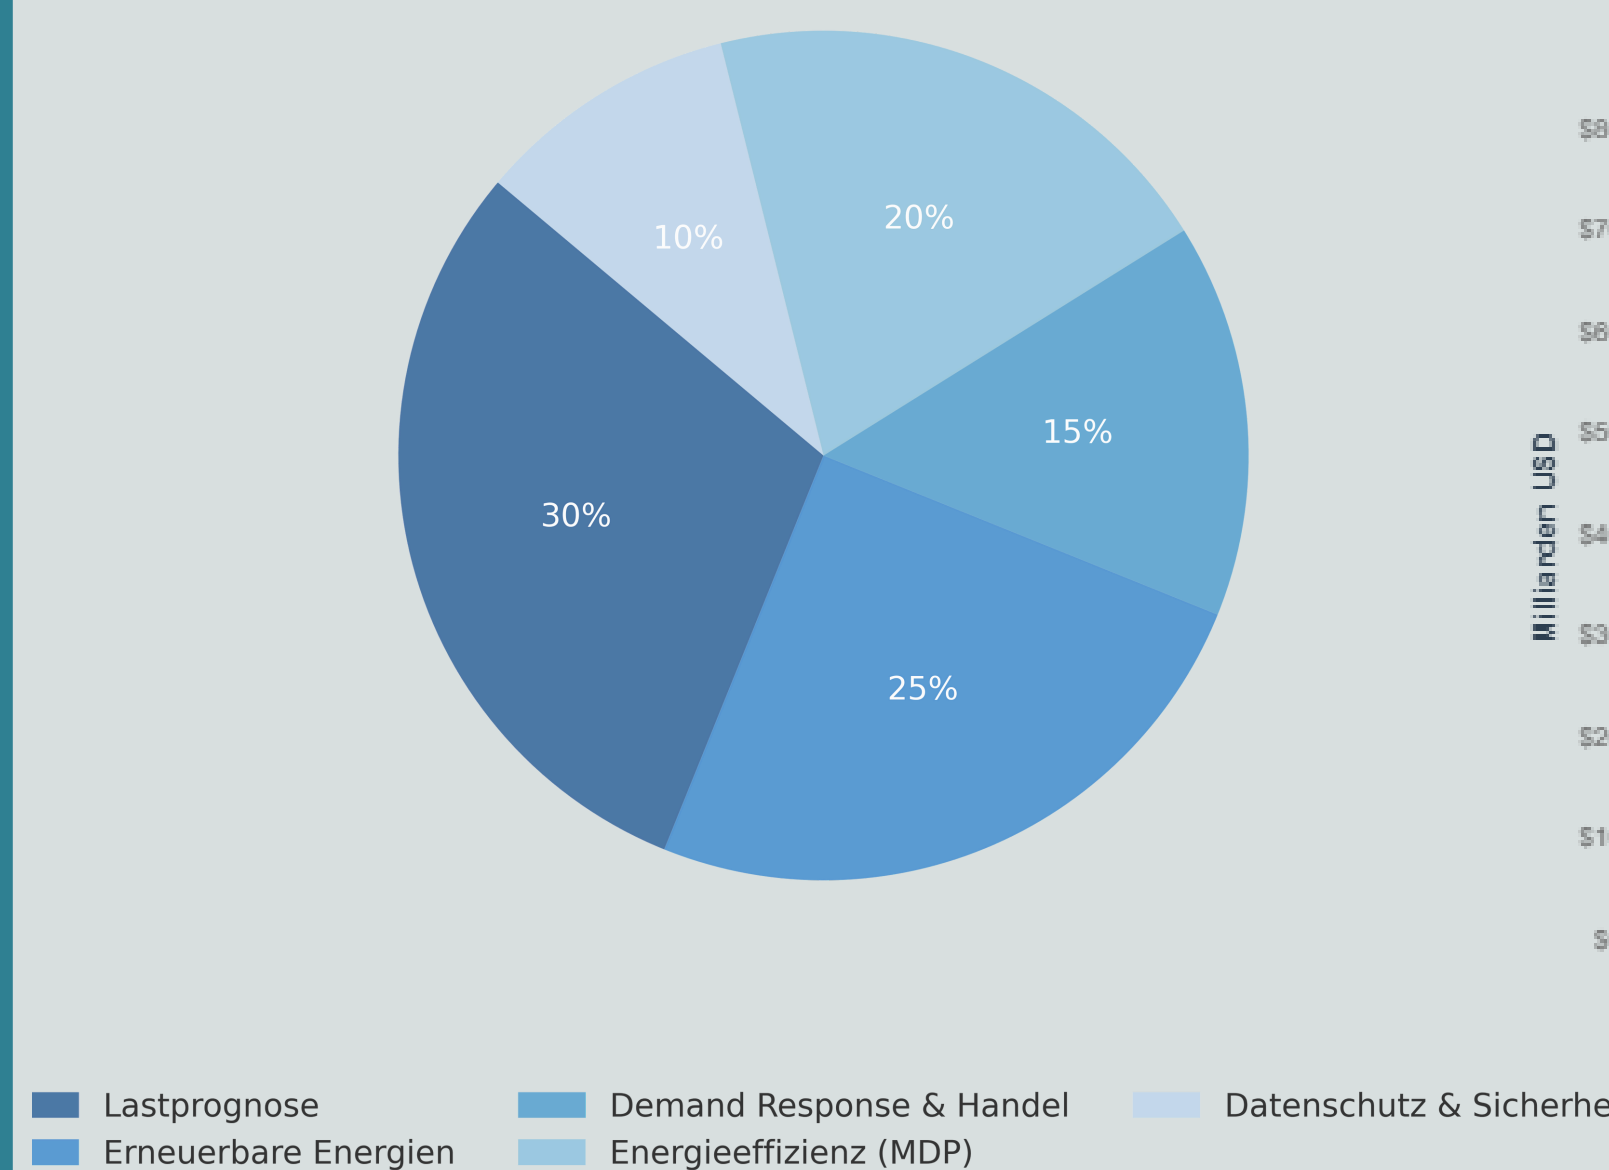
OTH  
Amberg-Weiden

## FL IM EINSATZ: SEKTORENÜBERBLICK

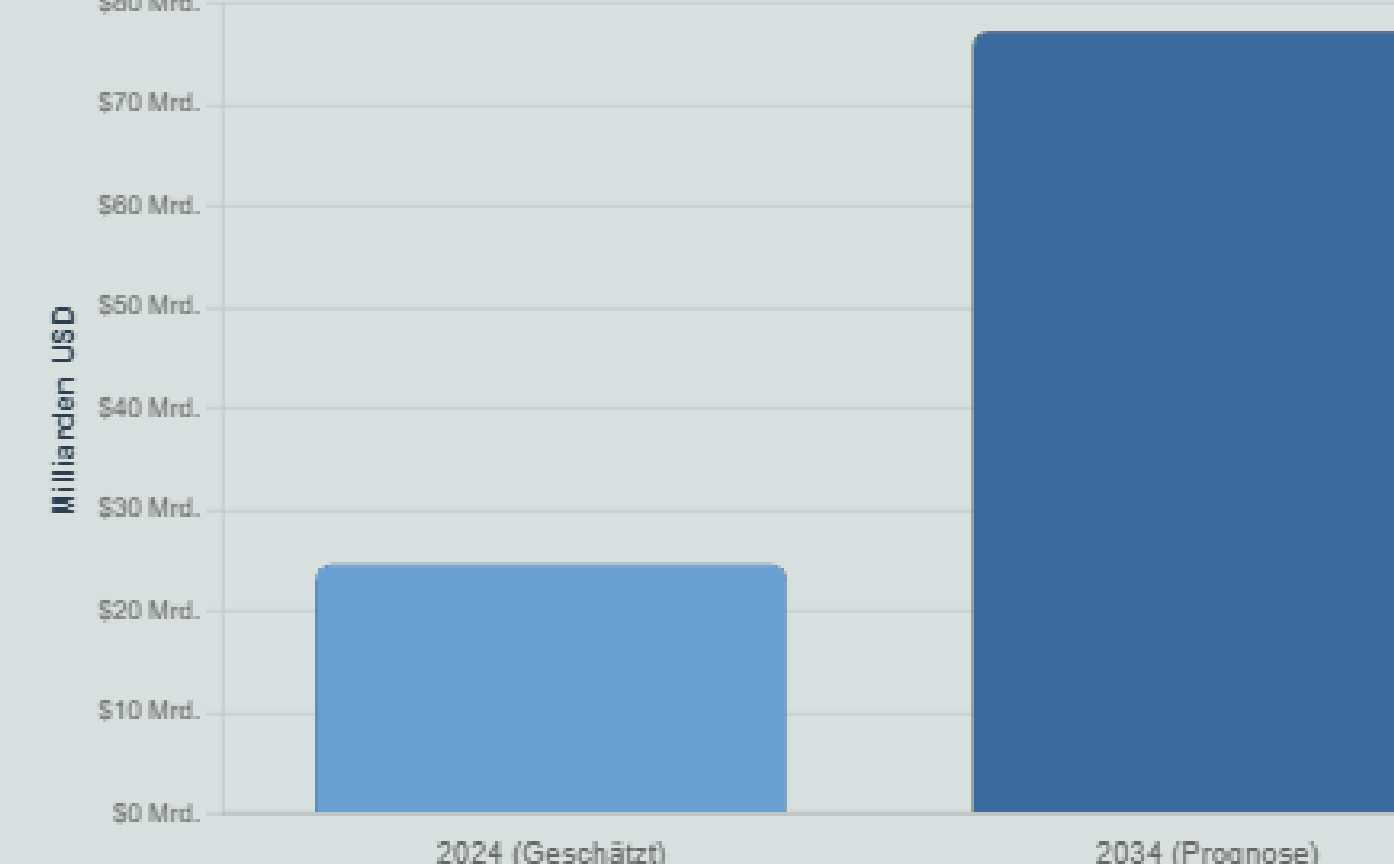
FL transformiert Schlüsselbereiche der Energieversorgung durch datenschutzfreundliches, kollaboratives Lernen:

- **Energieerzeugung:** Präzisere Wind- & Solarerträge und effektive Echtzeit-Diagnose von Anomalien in PV-Anlagen.
- **Smart Grids (Übertragung & Verteilung):** Stärkt Netzsicherheit (Cyberangriffe, Störungen) und optimiert Stabilität & Lastprognosen.
- **Energieverbrauch:** Unterstützt private Verbrauchsvorhersagen und ermöglicht NILM (Geräteverbrauch ohne Zusatzsensoren).

Verteilung der Anwendungsfelder in der FL-Energieforschung



Wachstum des globalen Smart Grid Datenanalyse-Marktes



## FL-METHODEN: DAS TECHNISCHE FUNDAMENT

Kernalgorithmus: Federated Averaging (FedAvg)


- **Prinzip:** Mittelwertbildung lokaler Modell-Updates.
- **Prozess:** Iterativ, kontinuierliche Verbesserung des globalen Modells.

Schutzmechanismen & Optimierung:

- **Datenschutz:** Differenzielle Privatsphäre (DP) schützt Updates durch Rauschen. Homomorphe Verschlüsselung (HE) ermöglicht Rechnen auf verschlüsselten Daten. Blockchain-FL sorgt für manipulationssichere Updates.
- **Effizienz & Ressourcen:** Optimierter Energieverbrauch durch dynamische Client-Teilnahme (z.B. via MDP, MARL) und angepasste Update-Frequenz. Kommunikation wird durch Quantisierung & Kompression reduziert. Client-Selektion wählt relevante/leistungsstarke Teilnehmer.

Spezifische Frameworks:

- **FedGrid:** Sichere Energieoptimierung im Smart Grid.
- **FedDiSC:** Effiziente Unterscheidung von Netzstörungen und Cyberangriffen.



## ERGEBNISSE & AUSBLICK

FL-Modelle erzielen vergleichbare Leistung wie zentrale Ansätze trotz mit Datenschutz!

Wichtige Erkenntnisse (Vor- und Nachteile):

- **Hohe Genauigkeit, robuste Sicherheit, deutliche Kommunikations- & Energieeffizienz, und erhöhtes dezentrales Vertrauen.**
- **Erschwerte Modelloptimierung durch steigende Komplexität (non IID-Datenproblem), fehlende Standardisierung und mögliche Sicherheitsrisiken**



## FAZIT UND ZUKUNSPERSPEKTIVE

Federated Learning revolutioniert die Energieversorgung, indem es datengetriebene Innovation ermöglicht, Effizienz und Sicherheit von Smart Grids steigert – bei gleichzeitiger Wahrung der Privatsphäre. Zentrale Forschungsschwerpunkte:

- **Skalierbarkeit & Robustheit:** FL-Algorithmen, die Millionen Clients standhalten und ausfallsicher sind.
- **Edge-Integration:** Echtzeit-Analysen direkt an der Quelle zur Reduktion von Latenz.
- **Datenschutzmechanismen:** Effiziente DP/HE-Lösungen für schwache Geräte.
- **Hybrid-Ansätze:** Kombination von FL mit z.B. Reinforcement Learning für intelligente Netzsteuerung.
- **Standardisierung:** Technische & rechtliche Grundlagen für flächendeckende Einführung.

### LITERATURVERZEICHNIS (REFERENCES)

1. H. Gupta et al., "FedGrid: A Secure Framework with Federated Learning for Energy Optimization in the Smart Grid," *Energies*, vol. 16, no. 24, p. 8097, 2023.
2. I. Ait Abdelmoula et al., "Federated learning for solar energy applications: A case study on real-time fault detection," *Solar Energy*, vol. 282, p. 112942, 2024.
3. M. A. Husnoo et al., "FedDISC: A Computation-efficient Federated Learning Framework for Power Systems Disturbance and Cyber Attack Discrimination," *arXiv:2304.03640*, 2023.
4. X. Cheng et al., "A Review of Federated Learning in Energy Systems," *Proc. IEEE/IAS 1CPSE Asia*, pp. 2089–2095, 2022.
5. A. Grataloup et al., "A review of federated learning in renewable energy applications: Potential, challenges, and future directions," *arXiv:2312.11220*, 2023.
6. X. Han et al., "Energy-Efficient Wireless Federated Learning via Doubly Adaptive Quantization," *arXiv:2402.12957*, 2024.
7. Y. Li et al., "A Blockchain-based Decentralized Federated Learning Framework with Committee Consensus," *arXiv:2404.00773*, 2024.
8. Z. Zhang et al., "Federated Learning for Smart Grid: A Survey on Applications and Potential Vulnerabilities," *arXiv:2409.10764*, 2025.
9. H. Zhang et al., "Energy-Aware Client Scheduling for Wireless Federated Learning with Energy Harvesting Devices," *arXiv:2405.10513*, May 2024.
10. A. Singh et al., "A MARL-Based Energy-Aware Client and Model Selection Scheme for Federated Learning," *arXiv:2405.08183*, May 2024.
11. S. Wang et al., "Adaptive Federated Learning in Resource-Constrained Edge Computing Systems," *arXiv:1911.02417*, 2019.
12. I. Nguyen et al., "Federated Learning for Smart Grid: A Comprehensive Survey," *arXiv:2201.11248*, Jan. 2022.
13. M. R. Orfatara et al., "Towards Energy-Aware Federated Learning in Green Smart Grid," *arXiv:2312.11220*, Dec. 2023.
14. J. Schmidt et al., "Federated Learning for the Energy Sector: Applications and Challenges," *arXiv:2208.1094v1*, Aug. 2022.